

Administración de Base de datos Corporativas

ACT. Marco Teórico: Investigación.
Docente: Ing. Juan Carlos Hernández Marín

7º SEMESTRE

GRUPO: M

Investigadores:

- **Kim Martínez Taesoo**
[DATA WAREHOUSE]
- **Zertuche Zamora Sergio Gabriel**
[PROBLEMAS DE CLASIFICACION]
- **Sánchez Morales Jesús**
[BASES DE DATOS]

MOD Masters:

- **Andrade Nieto Isaac Yireel**
- **Hernández Flores Lluvia Rubi**

EQUIPO #1



CONCEPTO DE BASE DE DATOS

Una base de datos o banco de datos es una herramienta que almacena información perteneciente a un mismo contexto, organizada y sistematizada lógicamente para su posterior recuperación, análisis o transmisión. Una biblioteca, un listado completo de clientes o el historial de las páginas visitadas en un navegador web son algunos ejemplos de bases de datos.

Las bases de datos responden al cometido de almacenar y organizar la información para poder acudir a ella posteriormente, lo que ha sido una necesidad de la humanidad desde tiempos remotos. Sin embargo, solo tras el surgimiento de la electrónica y la computación, se ha podido satisfacer a muy gran escala, almacenando enormes cantidades de datos en espacios físicos limitados, a través de su conversión en señales eléctricas o magnéticas.

Actualmente, el manejo de las bases de datos se lleva a cabo mediante sistemas de gestión llamados DBMS (siglas en inglés de Database Management Systems, “Sistemas de Gestión de Bases de Datos”). Este tipo de software permite el almacenamiento ordenado y la rápida recuperación de la información, sacando así provecho a la automatización y las interfaces digitales.

Las bases de datos se pueden organizar de acuerdo a diferentes modelos y paradigmas, cada uno dotado de características, ventajas y desventajas, según su estructura, su jerarquía, su capacidad de transmisión o de interrelación, entre otros criterios posibles. Estas diferencias constituyen el campo de los modelos de base de datos y permiten el diseño y la implementación de algoritmos y otros mecanismos lógicos de gestión para administrar los datos guardados.

Tipos de bases de datos

Existen diferentes formas de clasificar las bases de datos, atendiendo a características puntuales: su variabilidad, su estructura o su contenido.

Según su variabilidad

Dependiendo de cómo sean los procesos de acceso y modificación de los datos, es decir, su variabilidad, se puede distinguir entre:

- **Bases de datos estáticas.** Típicas de la inteligencia empresarial y otras áreas de análisis histórico, son aquellas de las cuales se puede extraer información, pero no modificar la ya existente, o sea que permiten únicamente la lectura de sus datos, no su reescritura.
- **Bases de datos dinámicas.** Son aquellas que además de las operaciones básicas de consulta (lectura), permiten manejar procesos de actualización, reorganización, añadidura y borrado de información.

Según su estructura

Dependiendo de cómo se encuentra organizada la información en una base de datos, se puede distinguir entre:

- **Bases de datos jerárquicas.** Son aquellas cuya información se dispone en estructura de árbol invertido, de manera tal que de cada nodo de información se desprenden otros nodos subsiguientes.
- **Bases de datos de red.** Son aquellas cuyos registros no están conectados entre sí de manera jerárquica, sino a través de enlaces en una red de información.
- **Bases de datos relacionales.** Son aquellas cuya información se dispone en tablas conocidas como “relaciones”, compuestas por un conjunto de campos y registros, y que se comunican entre sí mediante llaves primarias y foráneas.
- **Bases de datos multidimensionales.** Son aquellas cuyos datos se ordenan en una sola tabla, añadiendo un campo por cada métrica o hecho registrado.
- **Bases de datos orientadas a objetos.** Son aquellas que representan la información mediante objetos generados a través de un lenguaje de programación.

Según su contenido

De acuerdo a la naturaleza de la información que contienen, las bases de datos pueden ser:

- **Bases de datos bibliográficos.** Son aquellas que contienen los datos de referencia de algún material de lectura (como libros, periódicos y revistas), conocidos como *metadata*. No resguardan el contenido del texto, sino información clave, como el autor, el editor, el año de aparición, el área temática y el título del libro, entre otras posibilidades.
- **Bases de datos de texto completo.** Son aquellas que manejan textos íntegros, normalmente digitalizados o incluso fotografiados, por lo que son convenientes para preservar y organizar textos históricos o documentales, entre otras fuentes primarias.
- **Directorios.** Son listados enormes de datos personalizados, como direcciones de correo electrónico, números telefónicos, documentos de identidad, entre otros, que comparten un contexto o un interés específico.
- **Bases de datos especializadas.** Son aquellos repositorios de información especializada o técnica, pensados a partir de las necesidades de un público determinado, como el académico.

Ejemplos de bases de datos

Algunos ejemplos de bases de datos a lo largo de la historia son:

- **Guías telefónicas.** En desuso en la actualidad, estos voluminosos libros solían contener miles de números telefónicos asignados a hogares, empresas y particulares, para que el usuario pudiera disponer del que necesitaba. Eran engorrosos y pesados, pero exhaustivos.
- **Archivos personales.** El conjunto de los escritos de vida de un autor, investigador o intelectual son a menudo preservados en un archivo, organizado en base a la reproducción y descripción de los originales. Esto permite su consulta sin poner en riesgo el documento original.
- **Bibliotecas públicas.** Las bases de datos de estas instituciones contienen miles o cientos de miles de registros pertenecientes a cada título disponible para préstamo, ya sea en sala o circulante, y del que puede haber más de un ejemplar en el depósito. Los bibliotecólogos se encargan de diseñar estos sistemas y velar por su funcionamiento.
- **Registros de transacciones.** El conjunto de operaciones realizadas con una tarjeta de crédito, las llamadas realizadas con un celular o cualquier otro tipo de transacciones comerciales cotidianas generan un conjunto de datos analizables.
- **Historial médico.** Cada vez que alguien acude a un hospital, se actualiza la información respecto a su salud, incorporando el diagnóstico y tratamiento recibidos, así como otros detalles médicos en un único archivo. Así, en caso de que se requieran datos específicos sobre el paciente, podrán ser consultados con rapidez.

IMPACTO QUE TIENE EN UNA ORGANIZACIÓN

Contar con una buena base de datos ayuda mucho en una campaña de Marketing Directo. Es por ello que cada día tienen mayor importancia las bases de datos.

En la actualidad, las bases de datos son de vital importancia para cualquier tipo de organización, ya que la recopilación de datos dentro de una empresa o institución hace que se puedan tomar mejor las decisiones y definir de manera más precisa las estrategias a seguir.

Las bases de datos de empresas que contienen teléfono (tanto fijo como móvil), correo electrónico, datos de empresa, e incluso su facturación y número de trabajadores, hace que tenga un importante valor para otras empresas que quieran realizar una campaña de marketing ofreciendo sus servicios.

El poder hacerse con una buena base de datos, supone poder realizar una campaña de marketing para la posible captación de nuevos clientes que sin una buena bbdd sería muy complicado poder realizar. La utilización de la bases de datos combinándolo con los diferentes canales, bien por medio del contact center, un mailing, e-mailing... se pueden obtener muy buenos resultados comerciales en una campaña de marketing.

Son muchas las personas y organizaciones que utilizan las bases de datos como método de encontrar información de forma más rápida y con menos riesgo de pérdidas, ya que la información ayuda de una manera significativa en la toma de decisiones.

Las bases de datos no solo proporcionan grandes facilidades, rapidez y actualización en la información, sino que además nos dan una cantidad de funciones con un alto nivel de ventajas a nuestro favor, como, por ejemplo, permitir el almacenamiento y la recuperación de la información necesaria en cada momento en base a unos objetivos concretos.

En el mercado actual es inviable la no utilización de bases de datos en el mundo empresarial, todo tiene que estar registrado y organizado para poder ser ágiles y competitivos.

Importancia de una buena base de datos

Hoy en día todas las empresas cuentan con bases de datos que utilizan como una de sus herramientas principales para tener contacto con los clientes. Las bases de datos se utilizan para almacenar y clasificar la información específica de cada cliente, nombre y apellido, gustos, preferencias, perfiles en redes sociales, correo, número telefónico, ubicación, y una larga lista de datos, siempre lista para su utilización en el desarrollo de diferentes campañas.

En una empresa las bases de datos tienen diferentes funciones como monitorear los procesos de compra de clientes, mantener el contacto con ese comprador potencial estableciendo una comunicación más personalizada, cálida y que le genere confianza al cliente, desarrollar estrategias de marketing con mayor impacto, elaborar campañas de email marketing o mensajería masiva, dar a conocer las promociones u ofertas del negocio, establecer una lista VIP según características que tengan beneficios añadidos, ofrecer muestras gratis de un nuevo producto o servicio, invitar a eventos, reuniones y/o talleres, dar información que genere valor en la audiencia.

Un sinnúmero de posibilidades para la utilización de los datos recopilados y almacenados. En este sentido es de suma importancia el buen mantenimiento y la buena clasificación de los datos, para poder tener un acceso rápido y preciso al contenido, lo que facilitará mucho el trabajo a realizar.

Algunas ventajas de contar con una buena base de datos

Cada día son más las empresas que cuentan con una base de datos de sus clientes, una tarea que suele costar en un principio pero que luego suele dar muy buenos resultados y solo exige una labor de mantenimiento y actualización incluyendo a los nuevos clientes y actualizando los datos. Para las empresas una base de datos suele resultar una herramienta fundamental para su trabajo ya que ayuda a realizar cualquier tipo de acción. En las bases de datos se refleja información del cliente, ofreciendo más seguridad en los datos y así evitar que se pierdan.

Tener informatizada la base de datos tiene numerosas ventajas para las empresas, vamos a mencionar algunas de ellas:

- **Ley de Protección de Datos**

La nueva Ley de Protección de Datos exige cambios importantes para mejorar la seguridad, sobre todo en la seguridad de los datos personales y en la responsabilidad que tienen las empresas al almacenarlos. La Ley de Protección de Datos exige el tratamiento de los mismos de la manera adecuada y ve cuáles se puede recopilar y cuáles no. Para ello las empresas tienen que contar con equipos que tengan garantías de seguridad y también deben de utilizar programas difíciles de hackear.

- **Control de ventas**

Con las bases de datos se puede obtener y clasificar la información para controlar las ventas. Con lo que se recoja en las bases de datos se podrá saber cuáles son los productos más vendidos, cuales son los más devueltos, los más consultados y los más vendidos dependiendo la época del año.

- **Reducción de errores**

Cuando se tiene la base de datos informatizada es menor la posibilidad de errores y es imposible que se traspapelen pedidos ni que se mezclen con otros. Si éste método funciona será mayor la satisfacción de los clientes y así la empresa recibirá menos quejas. Las bases de datos ayudaran a ver equivocaciones de clientes como puede ser un pedido por duplicado. En este caso la empresa se pondría en contacto con la persona para comprobar la solicitud.

- **Campañas de marketing**

La finalidad de una campaña marketing es personalizarla haciendo que cada cliente se sienta importante y único. De esta forma se conseguirá un incremento en las ventas y un buen funcionamiento para que la campaña obtenga mayores beneficios. Al tener los datos personalizados resulta más fácil crear una newsletter o crear campañas para determinados sectores de clientes.

- **Ventajas respecto al personal**

Las bases de datos sirven para facilitar trabajo a los trabajadores. una vez que los mismo estén familiarizados con la base de datos el trabajo será más rápido, más sencillo y más fácil,



Razones para crear una base de datos

Para las empresas una base de datos es una herramienta potente en la que guarda y mantiene información concreta de los clientes. A la hora de fidelizar clientes hay que tener en cuenta sus hábitos, sus gustos, así como sus perfiles de compra para tratar de impactar en los mismos de la manera más eficaz. Las empresas pequeñas son las que más necesitan tener una base de datos para sacar el máximo rendimiento a su relación con los clientes.

Existen muchas razones para que las empresas creen una base de datos:

- Una base de datos permite disminuir la inversión entre diversas acciones de marketing menos segmentadas y eficaces. En el mundo online es importante tener un público que tengan parecido los gustos e intereses.
- Los descuentos y cupones promocionales son más eficaces y están divididos por gustos, cada cuanto tiempo se compra, los productos comprados, el ticket, ecétera.
- Con una base de datos de clientes se podrá dividir en segmentaciones. Analizando los datos de facturación las empresas podrán realizar
- Una base de datos mejora la fidelización. Al tener datos de los clientes se pueden tener información como cuales son los que más compran, cuando y se puede ofrecer descuentos para obsequiar su fidelidad.
- Las empresas que tengan una buena base de datos puede comercializar campañas automatizadas de envío de correos electrónicos y así incrementarán sus ventas sin tener que parar la actividad diaria.

invoice_line
+ field: id_line
+ field: id_invoice
+ field: id_article
+ field: amount
+ field: total_price

Vemos que es una tabla de hechos porque es una tabla transaccional, representa una medida detallada de un hecho pasado, se utiliza para la operativa de la empresa y su existencia depende de que el evento ocurra.

Tablas de dimensiones o maestras

Estas tablas son las encargadas de proporcionar un contexto descriptivo dentro de las tablas de hechos. Tienden a ser mucho más estáticas que una tabla de hechos, es decir, no crecen tanto como las tablas de hechos y se modifican poco. En la operativa de la empresa suelen ser transversales y se utilizan en diferentes contextos.

Ejemplo

En nuestro ejemplo, vemos cómo la dimensión “article” es la definición para el negocio de qué es un artículo de venta. En nuestro caso, tiene una descripción, una foto asociada, un precio, etc.

article
+ field: id_article
+ field: description
+ field: photo
+ field: dimensions
+ field: price

Tablas normalizadas y desnormalizadas

Cuando hablamos de tablas normalizadas nos referimos a aquellas tablas que evitan el almacenamiento de datos repetitivos.

Tabla normalizada:

id_line	id_invoice	id_article	amount	total_price
line_1	invoice_1	article_a	2	100
line_2	invoice_1	article_b	1	100
line_3	invoice_1	article_a	4	200

Tabla desnormalizada:

id_li ne	id_inv oice	article_descr iption	article_dime nsions	article_p hoto	amo unt	total_p rice
line_ 1	invoice _1	rectangle box	100 x 200	uri://pho to_a	2	100
line_ 2	invoice _1	square box	100 x 100	uri://pho to_b	1	100
line_ 3	invoice _1	rectangle box	100 x 200	uri://pho to_c	4	200

By: Andrade Nieto Isaac Yireel

CONEXION CON PROBLEMAS DE CLASIFICACION

Las bases de datos y los problemas de clasificación en aprendizaje automático mantienen una **relación simbiótica y fundamental** dentro del ecosistema de ciencia de datos. Las bases de datos, como sistemas organizados para almacenar y recuperar información estructurada (Codd, 1970), **constituyen la materia prima esencial** sobre la cual se construyen y entrenan los modelos de clasificación. Esta interdependencia se manifiesta en múltiples niveles del flujo analítico, desde la recolección de datos hasta la implementación de modelos predictivos en producción.

1. Las Bases de Datos como Fuente de Datos para Clasificación

Los problemas de clasificación—que buscan asignar etiquetas categóricas a observaciones basándose en características observadas (Hastie et al., 2009)—**dependen críticamente de la calidad, integridad y estructura** de los datos almacenados en bases de datos. La información organizada en tablas relacionales, como clientes, transacciones o historiales médicos, proporciona los **atributos (features)** y las **etiquetas objetivo (target labels)** necesarios para entrenar algoritmos supervisados. Por ejemplo, una base de datos de marketing con campos como frecuencia_compra, monto_promedio y categoría_producto_favorito puede alimentar un modelo para clasificar clientes como "alto valor", "medio valor" o "bajo valor" (según reglas de negocio definidas), apoyando así campañas de marketing personalizado.

La **estructuración lógica** de los datos—ya sea en modelos jerárquicos, relacionales o dimensionales—facilita la extracción de conjuntos de datos (datasets) coherentes para el aprendizaje automático. Como señala Han, Kamber y Pei (2011), "la minería de datos y el aprendizaje automático son procesos que extraen conocimiento de grandes repositorios de datos; sin un almacenamiento estructurado y accesible, estos procesos serían ineficientes o imposibles" (p. 28).

2. Clasificación como Herramienta que Valoriza la Base de Datos

La relación es bidireccional. Los modelos de clasificación **agregan valor estratégico** a los datos almacenados, transformando datos pasivos en **conocimiento activo y predictivo**. Una base de datos de clientes, por sí sola, es un repositorio histórico. Pero al aplicar un modelo de clasificación que predice la propensión a la compra, se genera una **nueva capa de información (scores, probabilidades)** que puede ser almacenada de nuevo en la base de datos, enriqueciéndola. Este ciclo—**almacenar** → **analizar/clasificar** → **retroalimentar**— convierte a la base de datos en un sistema vivo de inteligencia empresarial. Como destacan Provost y Fawcett (2013), "la ciencia de datos debe estar integrada en los sistemas de información de la empresa; los modelos predictivos deben desplegarse para operar sobre los datos en tiempo real o por lotes, y sus resultados deben persistir en las bases de datos operacionales" (p. 78).

3. Ejemplos Concretos de Conexión

- ❖ **Clasificación de Riesgo Crediticio:** Un banco utiliza su **base de datos transaccional** (historial de pagos, saldos, movimientos) para entrenar un modelo que clasifique a nuevos solicitantes en categorías de riesgo (A, B, C, D). El modelo se ejecuta periódicamente, y su output (la clasificación) se almacena en la **base de datos de clientes**, informando decisiones automatizadas.
- ❖ **Diagnóstico Médico Asistido:** Un hospital utiliza su **base de datos clínica** (síntomas, resultados de laboratorio, historiales) para entrenar un clasificador que ayuda a diagnosticar una enfermedad. El sistema consulta la base de datos en tiempo real para nuevas entradas y sugiere una clasificación (ej. "alto riesgo"), que un profesional verifica y registra.
- ❖ **Filtrado de Spam:** Un servicio de email almacena metadatos y contenido de millones de correos en una **base de datos masiva**. Un algoritmo de clasificación (como Naïve Bayes o SVM) se entrena con estos datos etiquetados (spam/no spam) y se integra en el sistema, consultando y clasificando nuevos mensajes al instante, basándose en patrones aprendidos de la base histórica.

RELACIÓN CON DATAWAREHOUSE

En el campo del Data Engineering, el diseño eficiente de bases de datos es esencial para manejar grandes volúmenes de datos y proporcionar análisis efectivos. A lo largo de mi experiencia como Data Engineer, he trabajado con los principales sistemas de relación de datos y he observado cómo los modelos de relación entre tablas juegan un papel crucial en la organización, mejorando el mantenimiento y la optimización de las consultas en nuestro Data Warehouse.

Entre los modelos más destacados se encuentran el modelo estrella, el modelo copo de nieve y el modelo galaxia. Cada uno de ellos tiene sus propias características, ventajas y desventajas, y se eligen en función de las necesidades específicas del negocio y las características de los datos.

En este post, exploraremos en detalle estos tres modelos, proporcionando una guía clara sobre cuándo debemos elegir uno u otro dependiendo de nuestras necesidades funcionales y no funcionales.

Hechos, dimensiones y normalización

Podemos dividir todos nuestros datos en dos categorías: tablas de hechos o tablas de dimensiones (maestros).

Tablas de hechos

Las tablas de hechos contienen datos sobre eventos ocurridos. Un hecho suele presentarse como un dato cuantitativo y transaccional, representando una métrica clave o una medida de negocio.

Ejemplo

En un Data Warehouse donde estemos almacenando información de facturación, la tabla `invoice_line` que contiene la información detallada de cada línea dentro de una factura, sería una tabla de hechos.

Conclusión

Las **bases de datos** y los **problemas de clasificación** no son dominios aislados, sino eslabones interconectados en la cadena de valor de los datos. Las bases de datos proporcionan el **sustento estructural y la materia prima** (datos limpios, integrados y accesibles) sin los cuales los modelos de clasificación no podrían existir. A su vez, los modelos de clasificación **potencian el valor empresarial** de las bases de datos, transformando datos almacenados en **predicciones accionables** que mejoran la toma de decisiones, automatizan procesos y generan ventajas competitivas. En la era de la inteligencia artificial, diseñar bases de datos con una visión analítica (considerando futuras necesidades de ML) y construir modelos de clasificación con una comprensión profunda de la procedencia y estructura de los datos, es la clave para construir sistemas de información verdaderamente inteligentes y orientados al valor.

Bibliografía

- Codd, E. F. (1970). A relational model of data for large, shared data banks. *Communications of the ACM*, 13(6), 377–387. <https://doi.org/10.1145/362384.362685>
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media.
- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer-Verlag.
- Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). Wiley.
- Provost, F., & Fawcett, T. (2013). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media.

PROBLEMAS DE CLASIFICACIÓN

1. Definición y Concepto General

Un **problema de clasificación** es aquel en el que buscamos predecir una variable cualitativa o categórica.

A diferencia de los problemas de regresión, que predicen valores numéricos continuos (como el precio de una casa o el tiempo de un corredor), la clasificación asigna una **etiqueta de clase** a una instancia de datos basándose en sus atributos.

- **Entrada (\$X\$):** Variables predictoras o atributos (ej. edad, ingresos, historial de compras).
- **Salida (\$Y\$):** Una categoría o clase (ej. "Compra/No Compra", "Cliente Riesgoso/Seguro", "Gato/Perro").

Es un proceso de **aprendizaje supervisado**, lo que significa que el modelo necesita un conjunto de datos históricos previamente etiquetados para "aprender" la función que mapea las entradas a las salidas.

2. Algoritmos de Clasificación: El caso de Naive Bayes

Uno de los algoritmos más utilizados para introducir la clasificación en bases de datos es el **Naive Bayes (Bayes Ingenuo)**. Este algoritmo se fundamenta en el Teorema de Bayes y trabaja con probabilidades condicionales.

Características Principales:

- **Ingenuidad (Naive):** Se le llama "ingenuo" porque asume que todos los atributos son independientes entre sí y no interactúan, lo cual simplifica enormemente el cálculo de probabilidades,. Aunque esta suposición raramente se cumple en datos reales, el algoritmo funciona sorprendentemente bien.
- **Modelo Probabilístico:** El entrenamiento genera una lista de probabilidades de clase (probabilidad a priori) y probabilidades condicionales según los atributos.

Proceso de Entrenamiento y Clasificación:

1. **Cálculo de Frecuencias:** Se cuenta cuántas veces aparece cada atributo asociado a una clase específica en el conjunto de entrenamiento (ej. cuántas "rosas" son de color "rojo").
2. **Corrección de Laplace:** Si una combinación de atributo y clase no existe en los datos (frecuencia cero), esto causa problemas matemáticos (divisiones por cero). Se aplica una corrección sumando 1 a todas las casillas para eliminar los ceros.
3. **Predicción:** Para una nueva instancia, se multiplican las probabilidades de sus atributos para cada clase posible. La clase con la mayor probabilidad resultante es la etiqueta asignada.

3. Evaluación del Desempeño (Métricas)

Para un administrador de bases de datos, no basta con crear el modelo; es necesario medir su precisión. Las métricas básicas incluyen:

- **Accuracy (Porcentaje de Acierto):** Mide la proporción de predicciones correctas sobre el total de casos.

- *Fórmula:*

$$\frac{\text{Total de Aciertos}}{\text{Total de Instancias}}$$

- **Tasa de Error:** Es el complemento del acierto. Representa el porcentaje de casos mal clasificados.

- *Fórmula:*

$$1 - \text{Accuracy}$$

Ejemplo Binario: Si se intenta predecir si un cliente compra o no (1 o 0), se comparan la columna de "Predicción" contra la columna de "Valor Real". Si coinciden, es un acierto; si no, es un error.

4. Diferencias Clave: Clasificación vs. Regresión vs. Clustering

Es vital distinguir entre estas técnicas para aplicar la correcta según la necesidad del negocio:

Característica	Clasificación	Regresión	Clustering (Agrupamiento)
Tipo de Variable (\$Y\$)	Cualitativa/Categórica (Clases, Etiquetas).	Cuantitativa/Numérica (Precios, Tiempos).	No hay variable \$Y\$ predefinida.
Tipo de Aprendizaje	Supervisado (requiere datos etiquetados).	Supervisado.	No Supervisado (descubre patrones ocultos).
Objetivo	Predecir a qué grupo pertenece una instancia (ej. ¿Es spam?).	Estimar un valor numérico (ej. ¿Cuánto ahorrará una persona?).	Encontrar particiones o segmentos homogéneos en los datos.
Ejemplo Corporativo	Determinar si un cliente es "Bueno" o "Malo".	Estimar el salario basado en estudios y profesión.	Segmentar clientes para campañas de marketing sin categorías previas.

5. Consideraciones sobre la Calidad de los Datos

Para que los algoritmos de clasificación como Naive Bayes funcionen correctamente en un entorno corporativo, la higiene de la base de datos es fundamental:

- **Limpieza de Datos:** Es necesario eliminar valores atípicos (*outliers*), ya que algoritmos como Naive Bayes funcionan mejor si la distribución de atributos es normal (Gaussiana).
- **Datos Faltantes:** Aunque Naive Bayes puede manejar datos perdidos al tratar probabilidades por separado, se recomienda realizar procesos de limpieza previos.
- **Normalización:** Es crucial igualar las sumas de frecuencias durante el entrenamiento para que las probabilidades sean comparables entre clases.

6. Consideraciones Avanzadas sobre la Calidad y Pre-procesamiento de Datos

Para que un modelo de clasificación sea efectivo en una base de datos corporativa, no basta con tener los datos almacenados; estos deben someterse a un riguroso proceso de higiene y transformación matemática. En algoritmos probabilísticos como Naive Bayes, este paso es crítico para evitar fallos aritméticos y sesgos.

A. Distribución de los Datos y Valores Atípicos

Muchos algoritmos de clasificación, incluyendo Naive Bayes, operan bajo la suposición de que los atributos siguen una **distribución Gaussiana** (o normal).

- **Impacto:** El modelo funciona mucho mejor si los datos se comportan de esta manera.
- **Acción Requerida:** Es vital identificar y **eliminar valores atípicos** (*outliers*) antes del entrenamiento. Aunque el algoritmo puede manejar ciertos datos perdidos tratando las probabilidades por separado, la presencia de ruido extremo distorsiona las curvas de probabilidad y reduce la precisión de la clasificación.

B. El Problema de la Frecuencia Cero

En bases de datos transaccionales, es común que ciertas combinaciones de atributos nunca hayan ocurrido históricamente (ej. un cliente que compre un producto específico en una región inusual).

- **El Error:** Si al entrenar el modelo, una frecuencia es **cero** (ej. "0 rosas amarillas" en el set de datos), al calcular la probabilidad condicional futura se producirá una multiplicación por cero, anulando toda la predicción.
- **Solución Técnica (Corrección de Laplace):** Para evitar errores de división o anulación, se aplica una técnica de suavizado llamada **Corrección de Laplace**. Esto consiste en sumar artificialmente un valor de **1 a todas las casillas** de la tabla de frecuencias. De esta forma, ninguna probabilidad es estrictamente cero, permitiendo que el modelo matemático funcione sin colapsar.

C. Normalización de Probabilidades

Al aplicar la corrección de Laplace (sumar 1 a los datos), se altera la suma total de las frecuencias.

- Para mantener la integridad estadística, es necesario **normalizar** los resultados. Esto implica recalcular los denominadores para que la suma de las probabilidades de cada clase siga siendo consistente.
- El objetivo es que las probabilidades sean comparables entre sí, asegurando que la suma de todas las posibilidades dentro de una clase (ej. probabilidades de todos los colores de flores) sea igual a 1 o al total ajustado.

7. Del Entrenamiento a la Predicción: La Mecánica Interna

Desde la perspectiva de la administración de datos, es fundamental entender que el "modelo" resultante no es una caja negra, sino una estructura de datos consultable.

- **El Modelo es una Tabla:** El resultado del entrenamiento en Naive Bayes es simplemente una lista optimizada de **probabilidades de clase** (probabilidad a priori) y una tabla de **probabilidades condicionales** para cada atributo.
- **Proceso de Clasificación (Runtime):** Cuando llega una nueva instancia a la base de datos (ej. un nuevo cliente o una nueva flor):
 1. El sistema busca las probabilidades correspondientes a los atributos de la nueva instancia en las tablas generadas.
 2. Se **multiplican** estas probabilidades individuales por la probabilidad de la clase.
 3. Se comparan los resultados finales entre las distintas hipótesis (ej. ¿es más probable que sea A o B?) y se asigna la etiqueta con el valor numérico más alto.

Conclusión

La implementación de problemas de clasificación en la administración de bases de datos corporativas permite trascender el simple almacenamiento de registros para generar inteligencia predictiva.

Al transformar variables cuantitativas y cualitativas en modelos supervisados, las organizaciones pueden automatizar decisiones complejas, como distinguir entre clientes rentables y riesgosos o clasificar inventarios automáticamente. Sin embargo, el éxito de estas implementaciones no reside únicamente en la elección del algoritmo (como Naive Bayes, Regresión Logística o SVM), sino en la calidad de los datos subyacentes. Como administradores de datos, la responsabilidad recae en garantizar la limpieza, la normalización y el correcto tratamiento de valores nulos o frecuencias cero. Solo mediante un pre-procesamiento riguroso y una validación constante a través de métricas de precisión (*accuracy*), se pueden construir sistemas de soporte a la decisión confiables y escalables.

CONEXION COMPLEMENTARIA

By: Andrade Nieto Isaac Yireel

Los temas de **problemas de clasificacion y el de Data Warehouse** se conectan perfectamente en el contexto del aprendizaje automático, aunque a primera vista puedan parecer distintos.

Aunque el conjunto de datawarehouse es clásicamente utilizado para problemas de regresión (como predecir el precio medio de una vivienda), sirve como un puente ideal para introducir problemas de clasificación en aprendizaje automático. Por ejemplo, podemos transformar su variable continua de precio en una variable categórica definiendo umbrales (como "vivienda cara" vs "vivienda económica"), convirtiendo así un problema de regresión en uno de clasificación binaria o multiclase. Esto permite ilustrar cómo los mismos atributos de las casas (número de habitaciones, ubicación, nivel socioeconómico del barrio, etc.) que originalmente predecían un valor numérico, pueden ser aprovechados por algoritmos como regresión logística, árboles de decisión o SVM para asignar categorías. De esta manera, data warehouse no solo enseña a modelar relaciones numéricas, sino que también se convierte en un ejemplo práctico para entender los fundamentos de la clasificación: desde la preparación de datos y la selección de características hasta la evaluación de modelos con métricas como precisión, recall o matrices de confusión. Así, un dataset aparentemente orientado a regresión se transforma en un laboratorio versátil para explorar ambos paradigmas del aprendizaje supervisado.

Puntos clave de conexión:

Transformación de problema: De regresión → clasificación.

- ❖ Mismas características, distinto objetivo: Se usan los mismos predictores (metros cuadrados, impuestos, etc.) pero para predecir una categoría en lugar de un número.
- ❖ Enseñanza de conceptos: Preprocesamiento, selección de modelo, evaluación, sobreajuste, etc., son comunes a ambos tipos de problemas.
- ❖ Versatilidad pedagógica: Muestra cómo un dataset puede adaptarse para enseñar múltiples técnicas en machine learning.

Bibliografía.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media.

Harrison, D., & Rubinfeld, D. L. (1978). Hedonic housing prices and the demand for clean air. *Journal of Environmental Economics and Management*, *5*(1), 81–102. [https://doi.org/10.1016/0095-0696\(78\)90006-2](https://doi.org/10.1016/0095-0696(78)90006-2)

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer-Verlag. <https://doi.org/10.1007/978-0-387-84858-7>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: With Applications in R* (2nd ed.). Springer-Verlag. <https://www.statlearning.com>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

DATA WAREHOUSE:

Un **Data Warehouse** (Almacén de Datos) es un sistema diseñado para la toma de decisiones que **agrega y consolida datos de múltiples fuentes heterogéneas** en un repositorio central, coherente y orientado a temas (Inmon, 2005). Su propósito fundamental es **apoyar el análisis empresarial** (Business Intelligence - BI), proporcionando una base histórica, integrada y no volátil para la minería de datos, el aprendizaje automático (ML) y la inteligencia artificial (IA) (Kimball & Ross, 2013).

La arquitectura de un data warehouse permite **ingerir grandes volúmenes de datos** desde sistemas operacionales (como ERP o CRM), transformarlos mediante procesos ETL (*Extract, Transform, Load*) y cargarlos en un modelo dimensional optimizado para consultas analíticas (Chaudhuri & Dayal, 1997). Esta preparación es crucial, ya que, como señala Han, Kamber y Pei (2011), "la calidad del descubrimiento de conocimiento está directamente limitada por la calidad de los datos subyacentes" (p. 43). Estas herramientas **permiten a los usuarios empresariales** explorar datos de manera autónoma para obtener *insights* estratégicos, democratizando el acceso a la información.

Los sistemas de almacenamiento de datos pueden ingerir grandes cantidades de datos de una amplia gama de sistemas de origen, incluidas bases de datos operativas, sistemas transaccionales y plataformas de gestión de relaciones con los clientes (CRM). Las herramientas de analytics de autoservicio permiten a los usuarios empresariales explorar y analizar estos datos para obtener **insights valiosos**.

El concepto surgió en la década de 1980 como respuesta a la necesidad de **integrar datos dispares** para el análisis corporativo. Sin embargo, con la explosión de nuevas fuentes (web, redes sociales, IoT), los data warehouses tradicionales enfrentaron desafíos de **escalabilidad, costo y complejidad** al intentar almacenar datos masivos no estructurados o semiestructurados (Thusoo et al., 2010). Surgieron así **alternativas modernas** como los data warehouses nativos en la nube (con elasticidad y costo bajo demanda) y los *lakehouses*, que buscan combinar la estructura y gobierno del data warehouse con la flexibilidad y economía de un data lake (Armbrust et al., 2021).

Conclusión:

El data warehouse se rige no como un simple repositorio, sino como la columna vertebral de un ecosistema analítico maduro. Su verdadero valor reside en su capacidad para transformar datos operativos crudos y dispersos en información histórica, integrada y confiable, que sirve como la "única versión de la verdad" para toda la organización (Kimball & Ross, 2013). Si bien la evolución hacia la nube y la convergencia con los data lakes (en modelos lakehouse) es una respuesta necesaria a la era del big data, el principio fundamental del data warehouse perdura: la gobernanza, la calidad y la estructuración intencional de los datos son prerequisites no negociables para un análisis avanzado y confiable. En última instancia, un data warehouse bien diseñado es el catalizador que permite a las empresas pasar de la recopilación de datos a la generación de conocimiento estratégico, alimentando de manera confiable las iniciativas de BI, ML e IA que definen la competitividad moderna.

Bibliografía

- Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. *Proceedings of CIDR '21*. https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf
- Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. *ACM SIGMOD Record*, 26(1), 65–74. <https://doi.org/10.1145/248603.248616>
- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). Wiley.
- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley.
- Thusoo, A., Sarma, J. S., Jain, N., Shao, Z., Chakka, P., Zhang, N., Antony, S., Liu, H., & Murthy, R. (2010). Hive – a petabyte scale data warehouse using Hadoop. *2010 IEEE 26th International Conference on Data Engineering (ICDE)*, 996–1005. <https://doi.org/10.1109/ICDE.2010.5447738>

Proceso de Llenado de la Base de Datos

Procesos Existentes para el Llenado de Bases de Datos

Existen diversos métodos para poblar una base de datos, los cuales pueden clasificarse de la siguiente manera:

A. Métodos Manuales

- **Inserción directa mediante interfaz:** Uso de herramientas gráficas como phpMyAdmin, SQL Server Management Studio o DBeaver para ingresar registro por registro.
- **Comandos SQL INSERT:** Escritura manual de sentencias INSERT para cada registro.

B. Métodos Automatizados

- **Scripts personalizados:** Programas desarrollados en lenguajes como Python, PHP o Java que automatizan la inserción de datos.
- **Herramientas ETL (Extract, Transform, Load):** Software especializado como Pentaho, Talend o SSIS que extraen datos de fuentes, los transforman y los cargan en la base de datos.
- **Comandos de importación masiva:** Utilidades propias de los DBMS como LOAD DATA INFILE (MySQL), BULK INSERT (SQL Server) o COPY (PostgreSQL).
- **APIs y web scraping:** Obtención automatizada de datos desde servicios web o sitios de internet.

C. Métodos Híbridos

- **Generación de datos sintéticos:** Creación de datos artificiales mediante herramientas como Faker o Mockaroo.
- **Migración desde otros sistemas:** Transferencia de datos desde archivos planos, hojas de cálculo u otras bases de datos.

Nuestro Enfoque: Método Directo con Transbordo desde Python

El proceso que implementamos para llenar nuestra base de datos combinó la búsqueda de una fuente confiable con la transferencia controlada de datos mediante un lenguaje de programación externo. A continuación, se desglosa detalladamente cada etapa:

Fase 1: Obtención de la Fuente de Datos

Decidimos utilizar **Kaggle** como nuestra plataforma de origen por las siguientes razones:

- Ofrece datasets curados y verificados por la comunidad
- Proporciona metadatos y documentación asociada
- Permite descargar los datos en formatos estandarizados (CSV, JSON, etc.)
- Cuenta con una amplia variedad de temáticas y volúmenes de datos

Seleccionamos cuidadosamente un dataset que se alinea con los objetivos de nuestro proyecto y que contara con la estructura y calidad necesarias para nuestro modelo de base de datos.

Fase 2: Roles y Responsabilidades del Equipo

El trabajo colaborativo fue fundamental para el éxito del proceso:

Cristopher se encargó del desarrollo técnico de la base de datos:

- Diseño del esquema basado en el modelo relacional (como se explica en las páginas 11-12 del marco teórico)
- Creación de las tablas considerando las relaciones entre entidades
- Implementación de llaves primarias y foráneas para garantizar la integridad referencial
- Configuración de tipos de datos adecuados

Lesly asumió la responsabilidad de la lógica de la base de datos:

- Definición de las reglas de negocio aplicables a los datos
- Establecimiento de restricciones y validaciones
- Determinación de las relaciones entre tablas
- Aseguramiento de la consistencia lógica de la información

Esta división de trabajo permitió que mientras uno construía la infraestructura técnica, el otro garantizara que esta infraestructura respondiera adecuadamente a los requerimientos funcionales del proyecto.

Fase 3: El Proceso de Transbordo desde Python

Aunque no utilizamos scripts automatizados en el sentido tradicional, empleamos **Python como lenguaje de transbordo**, lo que significa que lo usamos como intermediario para transferir los datos desde su fuente original hacia nuestra base de datos. El proceso fue el siguiente:

1. **Extracción desde Kaggle:** Descargamos el dataset en formato CSV desde la plataforma.
2. **Carga en Python:** Utilizamos Python con las bibliotecas apropiadas (pandas, sqlalchemy, etc.) para leer el archivo y preparar los datos.
3. **Validación y limpieza básica:** Aplicamos transformaciones mínimas para asegurar que los datos cumplieran con la estructura definida.
4. **Inserción controlada:** Ejecutamos la transferencia de los datos desde Python hacia nuestra base de datos, insertando los 11562 registros finales.

Este método de "transbordo" nos permitió mantener un control granular sobre el proceso sin necesidad de automatización completa, actuando Python como un puente entre la fuente de datos y nuestro sistema destino.

Razones por las que no utilizamos un Script Automatizado

Aunque los scripts automatizados son una opción válida y común en muchos contextos, tomamos la decisión consciente de no emplearlos por las siguientes razones:

Razones Técnicas

1. **Control y validación manual:** Al realizar un proceso semimanual con transbordo desde Python, pudimos inspeccionar visualmente los datos antes de su inserción definitiva, detectando posibles anomalías que un script automatizado podría pasar por alto.
2. **Complejidad del dataset:** El dataset seleccionado presentaba particularidades en su estructura que requerían decisiones puntuales durante la carga, las cuales eran más fáciles de manejar con intervención humana.

3. **Volumen manejable:** Con 11,562 registros, el volumen de datos era lo suficientemente moderado como para no requerir imperiosamente la automatización, permitiendo un proceso controlado sin sacrificar eficiencia.
4. **Garantía de integridad referencial:** La inserción controlada nos permitió verificar que cada registro respetara las relaciones establecidas entre tablas, evitando errores de llaves foráneas que podrían ocurrir en procesos masivos automatizados.

conclusión rápida: era más fácil y eficiente, observar nuestros datos con una fase manual que una automática directa o inyectable a la base de datos.

Razones Pedagógicas y de Aprendizaje

1. **Identificación de problemas estructurales:** Este enfoque permitió detectar y corregir sobre la marcha posibles deficiencias en el diseño de la base de datos, algo que un script automatizado habría ejecutado ciegamente.
2. **Alineación con el marco teórico:** Como se menciona en las páginas 6-10 del marco teórico sobre el impacto de las bases de datos en las organizaciones, comprender la naturaleza y calidad de los datos es fundamental para su aprovechamiento estratégico.

Razones Prácticas

1. **Documentación empírica:** El proceso manual generó un conocimiento “táctico” valioso sobre las características específicas de los datos y su comportamiento durante la inserción.

Resultado Final: 11,562 Datos Almacenados

Tras completar el proceso descrito, logramos poblar nuestra base de datos con **11,562 registros** de alta calidad. Y de hecho mientras hago este escrito el departamento de desarrollo sigue subiendo ese umbral a Día de hoy puedo informar de mas de 60k , demostrando que nuestra decisión fue correcta y el llenado de registros no se esta viendo comprometido por ningún problema externo.

Cómo las Investigaciones Previas Guiaron Nuestro Proceso

El marco teórico que desarrollamos previamente no fue un ejercicio académico aislado, sino que constituyó la brújula que orientó cada decisión en el proceso de llenado de nuestra base de datos.

Influencia del Concepto de Base de Datos (Página 2)

La definición fundamental de base de datos como "una herramienta que almacena información perteneciente a un mismo contexto, organizada y sistematizada lógicamente para su posterior recuperación, análisis o transmisión" nos recordó constantemente que nuestro objetivo no era simplemente almacenar datos, sino hacerlo de manera que facilitara su aprovechamiento futuro. Esto nos llevó a ser meticulosos en la organización y estructuración de los datos durante el proceso de transbordo desde Python.

Aportes de la Clasificación de Bases de Datos (Páginas 3-4)

El estudio de los diferentes tipos de bases de datos según su variabilidad, estructura y contenido fue determinante para:

- Hay que confirmar que nuestro diseño relacional era el adecuado para el tipo de información que manejaríamos
- Comprender que estábamos construyendo una base de datos dinámica (no estática), lo que implicaba considerar futuras operaciones de actualización y borrado
- Identificar que nuestro contenido correspondía a una base de datos especializada, orientada a un público con necesidades específicas como lo es una farmacia u hospital.

Impacto Organizacional de las Bases de Datos (Páginas 6-10)

Las secciones dedicadas al impacto en las organizaciones y la importancia de una buena base de datos nos sensibilizaron sobre la responsabilidad de nuestro trabajo. Conceptos como:

- ✓ "La recopilación de datos hace que se puedan tomar mejor las decisiones"
- ✓ "Las bases de datos no solo proporcionan grandes facilidades, rapidez y actualización, sino que además nos dan una cantidad de funciones con un alto nivel de ventajas"

Estos principios nos motivaron a asegurar que cada uno de los registros fuera insertado con la máxima calidad posible, entendiendo que de ellos podrían derivarse decisiones importantes.

Conexión con Problemas de Clasificación (Páginas 14-22)

Aunque nuestro objetivo inmediato era el llenado de la base de datos, la investigación sobre problemas de clasificación y su relación con las bases de datos nos hizo conscientes de que estábamos construyendo la materia prima para futuros análisis predictivos. Comprender que:

- ✓ "Las bases de datos constituyen la materia prima esencial sobre la cual se construyen y entrenan los modelos de clasificación"
- ✓ "La calidad, integridad y estructura de los datos almacenados" son críticas para el aprendizaje automático

Perspectiva del Data Warehouse (Páginas 24-25)

La sección sobre Data Warehouse nos proporcionó una visión a futuro de cómo nuestra base de datos podría integrarse en un ecosistema analítico mayor. Conceptos como:

- "Los sistemas de almacenamiento de datos pueden ingerir grandes cantidades de datos de una amplia gama de sistemas de origen"
- "La cobertura, la calidad y la estructuración intencional de los datos son requisitos no negociables para un análisis avanzado"

Estos principios reforzaron nuestra decisión de realizar un proceso de llenado controlado y cuidadoso.

Conclusión

El proceso de llenado de nuestra base de datos con 11,562 registros mediante el método directo con transbordo desde Python no fue una decisión arbitraria, sino el resultado de un análisis cuidadoso que consideró tanto el contexto tecnológico actual en México como las necesidades específicas de nuestro proyecto. La decisión de no utilizar scripts automatizados respondió a razones técnicas, pedagógicas y prácticas válidas que privilegiaron el control, la calidad y el aprendizaje sobre la mera eficiencia automatizada. El marco teórico desarrollado previamente se reveló no como un requisito académico a cumplir, sino como una guía práctica que iluminó cada etapa del proceso: desde el diseño de la estructura hasta la inserción final de los datos. La comprensión profunda de conceptos como tipos de bases de datos, tablas de hechos y dimensiones, y la relación con problemas de clasificación, nos permitió tomar decisiones informadas que garantizan no solo la funcionalidad presente de nuestra base de datos, sino también su potencial para integrarse en futuros desarrollos analíticos.

En última instancia, este proceso nos permitió trascender el simple almacenamiento de registros para generar una base de datos que, como señala nuestro marco teórico, constituye "la materia prima esencial" para la generación de conocimiento y la toma de decisiones fundamentadas.



BIBLIOGRAFIA:

La gran mayoría del texto aquí descrito este sujeto a su autor Isaac Yireel Andrade Nieto, tomando un punto de vista desde la experiencia en conjunto y comentarios de los desarrolladores, Espinosa Vazquez Cristopher, y Aguilar Gomez Lesly Dariana. también se utilizaron elementos externos como son investigaciones propias de este equipo de trabajo realizados por:

Kim Martínez Taesoo, Zertuche Zamora Sergio Gabriel y Sánchez Morales Jesus. y finalmente elementos externos de datos relevantes por la comunidad y datos encontrados o extraídos en internet como libros digitales, manuales o blogs profesionales.

Machine Learning y Python

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media. Guía práctica para implementar modelos de machine learning utilizando Python, relevante para nuestro uso de Python como lenguaje de transbordo.

McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media. Texto esencial para comprender el manejo de datos con Python, incluyendo la lectura de archivos CSV y la preparación de datos para inserción en bases de datos.

VanderPlas, J. (2016). *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly Media. Obra que cubre las herramientas fundamentales de Python para ciencia de datos, incluyendo manipulación de datos y visualización.

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley. Referencia esencial para comprender el modelado dimensional, las tablas de hechos y dimensiones que exploramos en nuestro marco teórico.

Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). Wiley.
Texto fundamental que establece los principios del data warehousing y su importancia en la inteligencia de negocios.

Artículos Científicos y complementarios.

Molina Marco, A. (2019). Bases de datos: Diseño y gestión. Garceta Grupo Editorial.
Obra en español que aborda el diseño y gestión de bases de datos en el contexto hispanohablante.

Hernández Orallo, J., Ramírez Quintana, M. J., & Ferri Ramírez, C. (2004).
Introducción a la minería de datos. Pearson Prentice Hall.

Texto en español que introduce los conceptos fundamentales de la minería de datos, incluyendo problemas de clasificación.

Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. *Proceedings of CIDR* '21. https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf

Artículo que presenta el concepto de lakehouse como evolución de los data warehouses tradicionales.

Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. *ACM SIGMOD Record*, 26(1), 65-74. <https://doi.org/10.1145/248603.248616>

Revisión fundamental de las tecnologías de data warehousing y procesamiento analítico en línea.

Thusoo, A., et al. (2010). Hive - a petabyte scale data warehouse using Hadoop. *2010 IEEE 26th International Conference on Data Engineering (ICDE)*, 996-1005. <https://doi.org/10.1109/ICDE.2010.5447738>

Artículo que describe la implementación de data warehouses a gran escala utilizando tecnologías de big data.

Harrison, D., & Rubinfeld, D. L. (1978). Hedonic housing prices and the demand for clean air. *Journal of Environmental Economics and Management*, 5(1), 81-102. [https://doi.org/10.1016/0095-0696\(78\)90006-2](https://doi.org/10.1016/0095-0696(78)90006-2)

Estudio que presenta el dataset de viviendas utilizado como ejemplo de conexión entre regresión y clasificación en nuestro marco teórico.