

SISTEMA DE GESTIÓN HOSPITALARIA

Base de Datos Corporativas — bd_marin

Aguilar Gomez Lesly Dariana

Kim Martínez Taesoo

Andrade Nieto Isaac Yireel

Zertuche Zamora Sergio Gabriel

Espinosa Vazquez Cristopher

Sánchez Morales Jesús

Hernández Flores Lluvia Rubi

TEMAS DESARROLLADOS

Bases de Datos

Conceptos, tipos, ventajas e impacto organizacional

Sánchez Morales Jesús

Data Warehouse

ETL, modelos estrella/copo de nieve, Business Intelligence

Kim Martínez Taesoo

Problemas de Clasificación

Naïve Bayes, métricas de precisión, conexión BD-ML

Zertuche Zamora Sergio Gabriel

Sistema Hospitalario bd_marin

Diseño, modelado e implementación en PostgreSQL 18.3

Equipo de Desarrollo

Algoritmo Apriori

Reglas de asociación sobre los 4 casos de uso del sistema

Espinosa Vazquez Cristopher

Actualización de Desarrollo

Comparativa Marco Teórico vs Informe Técnico bd_marin

Andrade Nieto Isaac Yireel

OBJETIVO DEL PROYECTO

Diseñar, modelar e implementar una base de datos relacional robusta para un Sistema de Gestión Hospitalaria en PostgreSQL 18.3, aplicando principios de administración de BD corporativas, con integridad referencial, reglas de negocio automatizadas mediante triggers, y capacidad analítica para decisiones estratégicas.

01

Cubrir 4 casos de uso hospitalarios reales: tipos sanguíneos, áreas, enfermedades y tratamientos

02

Implementar +15 tablas relacionales normalizadas con integridad referencial completa

03

Automatizar reglas de negocio mediante 5 triggers de validación en la capa de BD

04

Aplicar Algoritmo Apriori para extraer reglas de asociación con soporte, confianza y lift

Sistema organizado para almacenar, recuperar y gestionar información mediante DBMS.

Estáticas

Solo lectura · análisis histórico

Dinámicas


Lectura + escritura + borrado

Relacionales

Tablas con llaves primarias y foráneas

Multidimensionales

Una tabla, múltiples métricas



📌 Caso de uso en bd_marin: tabla tiposanguineos y compatibilidadesanguinea modelan estas relaciones con restricción UNIQUE sobre par (donante, receptor).

Repositorio central que consolida datos de múltiples fuentes para Business Intelligence, ML e IA.

EXTRACT



TRANSFORM



LOAD

Modelo Estrella

1 tabla hechos + dimensiones directas.
Consultas rápidas.

Copo de Nieve

Dimensiones normalizadas. Mayor
integridad, más joins.

Galaxia

Múltiples tablas de hechos compartiendo
dimensiones.

"El data warehouse es la columna vertebral de un ecosistema analítico maduro: transforma datos operativos en la única versión de la verdad para toda la organización."

Predecir una variable categórica asignando etiquetas a nuevas instancias mediante aprendizaje supervisado.

NAIVE BAYES

- 1. Calcular frecuencias de atributos por clase
- 2. Aplicar Corrección de Laplace (evitar $P=0$)
- 3. Normalizar probabilidades
- 4. Multiplicar $P(\text{clase}) \times P(\text{atributos} \mid \text{clase})$
- 5. Asignar etiqueta con mayor probabilidad

MÉTRICAS DE EVALUACIÓN

Accuracy = Total Aciertos / Total Instancias

Tasa de Error = 1 – Accuracy

Técnicas Comparadas

Técnica	Salida	Tipo
Clasificación	Categoría	Supervisado
Regresión	Número	Supervisado
Clustering	Grupos	No-Superv.

DESCRIPCIÓN DE LOS DATOS

60,000+

REGISTROS ALMACENADOS

Caso 1

Tipos Sanguíneos

tiposanguineos, compatibilidadesanguinea
propensiondpresion: Hipertensión / Hipotensión / Neutral

Caso 2

Áreas Hospitalarias

areashospital, ingresoshospitalarios
nivelurgencia: Alta / Media / Baja | aforomaximo > 0

Caso 3

Enfermedades por Temporada

catalogoenfermedades, consultas
origenbrote: Pandemia / Climatológica / Endémica...

Caso 4

Tratamientos y Medicamentos

tratamientos, medicinas, inventariomedicinas
umbralcosto: Extremo / Alto / Medio / Bajo

CRITERIOS DE CALIDAD Y VARIABLES CLAVE


15+ TABLAS DEL SISTEMA

- ▶ tiposanguineos | compatibilidadesanguinea
- ▶ areashospital | ingresoshospitalarios
- ▶ catalogoenfermedades | consultas
- ▶ tratamientos | medicinas | inventariomedicinas
- ▶ pacientes | personal | citas
- ▶ recetas | detallereceta
- ▶ ventasmedicina | detalleventa
- ▶ historialtratamientos


CORRECCIONES APLICADAS

- ✓ Restricciones CHECK en dominios categóricos (urgencia, origen brote, tipo medicina, umbral costo)
- ✓ Llaves foráneas nombradas explícitamente (fk_citas_doctor, fk_historial_paciente...)
- ✓ UNIQUE sobre par (donanteid, receptorid) para evitar compatibilidades duplicadas
- ✓ Secuencias automáticas de IDs y valores por defecto definidos
- ✓ Limpieza y validación manual antes de inserción en BD vía Python
- ✓ Normalización sin redundancias revisada por Sergio (3FN)

METODOLOGÍA — FLUJO DEL PROCESO



ROLES DEL EQUIPO



FUNCIONALIDADES IMPLEMENTADAS — TRIGGERS

5 triggers de validación automatizados directamente en la capa de BD (PostgreSQL)



fn_citas_validardoctor



Solo personal con rol 'Doctor' puede recibir citas médicas.



fn_venta_validarenfermero

Solo enfermeros pueden realizar ventas de medicamentos en farmacia.



fn_detventa_descontarinventario

Descuenta automáticamente el stock al registrar una venta.



fn_detventa_validarreceta

Bloquea venta de medicamentos con receta requerida si no existe.



fn_ingresos_validaraforo

Impide ingresos cuando el área alcanzó su capacidad máxima.

RESULTADOS OBTENIDOS

15+

Tablas relacionales

20+

Llaves foráneas

5

Triggers activos

60k+

Registros cargados

4


Casos de uso

Módulo	Tablas	Característica Clave
Tipos Sanguíneos	2	Tabla cruce donante-receptor + UNIQUE
Áreas y Aforos	2	Trigger validaraforo + CHECK urgencia
Enfermedades	2	origenbrote controlado + esendemica BOOL
Tratamientos/Medicinas	3	umbralcosto + receta + descuento stock
Módulos Transversales	6+	Pacientes, personal, citas, recetas, ventas

ALGORITMO APRIORI — REGLAS DE ASOCIACIÓN

Aplicado por: Espinosa Vazquez Christopher | Python + mlxtend | 4 Casos de Uso

Algoritmo Apriori Flujo



Soporte
Frecuencia global

Confianza
 $P(B|A)$
confianza real

Lift
 >1 = asociación positiva real

MÉTRICAS CLAVE

Soporte

% de transacciones que contienen el itemset completo
Mín. recomendado: 4%

Confianza

$P(B|A)$ — probabilidad de B dado que ocurre A
1.000 = regla perfecta

Lift

Qué tan más frecuente que por azar es la asociación
 >1 = asociación positiva real

🏆 Regla más fuerte (mayor soporte): [Donante_O-] $\leftrightarrow$ [Receptor_O-] | Soporte=11.8% | Confianza=100% | Lift=8.47

APRIORI — ITEMSETS FRECUENTES: DIAGNÓSTICO ↔ MEDICAMENTO

Todos los itemsets con Confianza = 100% — soporte entre 5% y 15%

Regla A → B	Soporte	Confianza	Frec.
Dx_Diabetes → Med_Metformina	15.0%	100%	150/150
Med_Metformina → Dx_Diabetes	15.0%	100%	150/150
Dx_Hipertension → Med_Enalapril	15.0%	100%	150/150
Med_Enalapril → Dx_Hipertension	15.0%	100%	150/150
Dx_Artritis → Med_Ibuprofeno	10.0%	100%	100/100
Dx_Asma → Med_Salbutamol	10.0%	100%	100/100
Dx_Cancer → Med_Dexametasona	10.0%	100%	100/100
Dx_Gastritis → Med_Omeprazol	10.0%	100%	100/100
Med_Paracetamol → Dx_Dengue	5.0%	50%	50/100
Med_Paracetamol → Dx_Obesidad	5.0%	50%	50/100

APRIORI — REGLAS DESTACADAS POR CASO

C1 Compatibilidad Sanguínea

Regla: [Donante_O-] ↔ [Receptor_O-]

Soporte: 11.8% Confianza: 100% Lift: 8.47

💡 El banco de sangre prioriza donadores O- para cualquier receptor — regla biyeccional perfecta.

C2 Áreas ↔ Urgencia

Regla: [Area_Cardiología/Oncología/UCI/Urgencias] → [Urgencia_Alta]

Soporte: 6.7% Confianza: 100% Lift: 3.73

💡 4 áreas se asocian 100% con urgencia alta. Consulta Externa se asocia a Urgencia_Baja (lift: 3.02).

C3 Enfermedades ↔ Temporada

Regla: [Enf_Rabies] ↔ [Tipo_Plaga Fauna] | [Temp_Otoño+Climatológica] ↔ [Malaria var. 623]

Soporte: 4.0% Confianza: 100% Lift: 25.00 ← máximo del estudio

💡 Lift=25 es el más alto del análisis. Permite anticipar brotes estacionales y preparar insumos.

C4 Costos ↔ Tratamientos ↔ Medicamentos

Regla: [CostoTrat_Medio + Med_Patente] → [Atención_Privado + CostoMed_Bajo + Duración_Temporal]

Soporte: 8.4% Confianza: 50.3% Lift: 1.35

💡 Confianza ~50% refleja mayor variabilidad. Útil para proyecciones de gasto y políticas de acceso.

IMPACTO EN SALUD DIGITAL — ESTADÍSTICAS

Contexto comparativo con sistemas similares en el sector salud a nivel global

Impacto en el Sector Salud Digital



Reducción errores
transfusión con
sistemas digitales



Reducción costos
operativos con
gestión BD hospitalaria



Mercado global HIS
2024 proyectado
\$8.9B

96%

Reducción de errores en transfusiones

OMS / ISBT 2023

30%

Reducción de costos operativos con gestión BD hospitalaria integrada

Frost & Sullivan 2023

\$8.9B

Mercado global de HIS (Hospital Information Systems) en 2024

MarketsandMarkets 2024

Crecimiento proyectado del mercado HIS — próximos 5

COMPARATIVA: bd_marin vs. Sistemas Hospitalarios Existentes

Exactitud Transfusiones

bd_marin: 100%

Industria: 78–84%

Reglas de negocio en BD

bd_marin: 5 triggers

Industria: Mayoría en app

Cobertura de casos

bd_marin: 4 casos + Apriori

Industria: 1–2 módulos

INTERPRETACIÓN DE RESULTADOS

✓ CONVERGENCIAS TEORÍA → PRÁCTICA

- Normalización 3FN: el modelo es relacional sin redundancias con FK explícitas
- Reglas de negocio en BD: los 5 triggers evitan dependencia de la app
- Apriori confirma patrones reales: Diabetes+Hipertensión lideran la demanda clínica
- Calidad de datos crítica: validación pre-inserción desde Python antes de subir

🔭 OPORTUNIDADES FUTURAS

- Data Warehouse sobre bd_marin: diagnósticos → dimensiones, ingresos → hechos
- Entrenar modelos de clasificación (Naive Bayes) usando itemsets Apriori como features
- Distinción OLAP vs OLTP: estrella/copo de nieve para analítica, 3FN para operación
- Índices y particionamiento para escalar más allá de 60k registros con alta concurrencia

CONCLUSIÓN

El Marco Teórico fue la brújula; bd_marin es la evidencia de que el diseño se materializó con solidez técnica. El Algoritmo Apriori confirmó con datos reales los patrones clínicos que el modelo relacional ya anticipaba en su estructura.

BASES SÓLIDAS

Normalización 3FN, integridad referencial y restricciones CHECK garantizan un modelo sin redundancias.

AUTOMATIZACIÓN

5 triggers embebidos en PostgreSQL hacen cumplir las reglas de negocio sin depender de la aplicación.

INTELIGENCIA

Apriori revela reglas de asociación accionables: gestión de sangre, brotes, costos y áreas críticas.

VISIÓN FUTURA

bd_marin es la materia prima lista para un Data Warehouse y modelos de clasificación con ML.