

Proceso de Llenado de la Base de Datos

Procesos Existentes para el Llenado de Bases de Datos

Existen diversos métodos para poblar una base de datos, los cuales pueden clasificarse de la siguiente manera:

A. Métodos Manuales

- **Insertión directa mediante interfaz:** Uso de herramientas gráficas como phpMyAdmin, SQL Server Management Studio o DBeaver para ingresar registro por registro.
- **Comandos SQL INSERT:** Escritura manual de sentencias INSERT para cada registro.

B. Métodos Automatizados

- **Scripts personalizados:** Programas desarrollados en lenguajes como Python, PHP o Java que automatizan la inserción de datos.
- **Herramientas ETL (Extract, Transform, Load):** Software especializado como Pentaho, Talend o SSIS que extraen datos de fuentes, los transforman y los cargan en la base de datos.
- **Comandos de importación masiva:** Utilidades propias de los DBMS como LOAD DATA INFILE (MySQL), BULK INSERT (SQL Server) o COPY (PostgreSQL).
- **APIs y web scraping:** Obtención automatizada de datos desde servicios web o sitios de internet.

C. Métodos Híbridos

- **Generación de datos sintéticos:** Creación de datos artificiales mediante herramientas como Faker o Mockaroo.
- **Migración desde otros sistemas:** Transferencia de datos desde archivos planos, hojas de cálculo u otras bases de datos.

Nuestro Enfoque: Método Directo con Transbordo desde Python

El proceso que implementamos para llenar nuestra base de datos combinó la búsqueda de una fuente confiable con la transferencia controlada de datos mediante un lenguaje de programación externo. A continuación, se desglosa detalladamente cada etapa:

Fase 1: Obtención de la Fuente de Datos

Decidimos utilizar **Kaggle** como nuestra plataforma de origen por las siguientes razones:

- Ofrece datasets curados y verificados por la comunidad
- Proporciona metadatos y documentación asociada
- Permite descargar los datos en formatos estandarizados (CSV, JSON, etc.)
- Cuenta con una amplia variedad de temáticas y volúmenes de datos

Seleccionamos cuidadosamente un dataset que se alinee con los objetivos de nuestro proyecto y que contara con la estructura y calidad necesarias para nuestro modelo de base de datos.

Fase 2: Roles y Responsabilidades del Equipo

El trabajo colaborativo fue fundamental para el éxito del proceso:

Cristopher se encargó del desarrollo técnico de la base de datos:

- Diseño del esquema basado en el modelo relacional (como se explica en las páginas 11-12 del marco teórico)
- Creación de las tablas considerando las relaciones entre entidades
- Implementación de llaves primarias y foráneas para garantizar la integridad referencial
- Configuración de tipos de datos adecuados

Lesly asumió la responsabilidad de la lógica de la base de datos:

- Definición de las reglas de negocio aplicables a los datos
- Establecimiento de restricciones y validaciones
- Determinación de las relaciones entre tablas
- Aseguramiento de la consistencia lógica de la información

Esta división de trabajo permitió que mientras uno construía la infraestructura técnica, el otro garantizara que esta infraestructura respondiera adecuadamente a los requerimientos funcionales del proyecto.

Fase 3: El Proceso de Transbordo desde Python

Aunque no utilizamos scripts automatizados en el sentido tradicional, empleamos **Python como lenguaje de transbordo**, lo que significa que lo usamos como intermediario para transferir los datos desde su fuente original hacia nuestra base de datos. El proceso fue el siguiente:

1. **Extracción desde Kaggle:** Descargamos el dataset en formato CSV desde la plataforma.
2. **Carga en Python:** Utilizamos Python con las bibliotecas apropiadas (pandas, sqlalchemy, etc.) para leer el archivo y preparar los datos.
3. **Validación y limpieza básica:** Aplicamos transformaciones mínimas para asegurar que los datos cumplieran con la estructura definida.
4. **Inserción controlada:** Ejecutamos la transferencia de los datos desde Python hacia nuestra base de datos, insertando los 11562 registros finales.

Este método de "transbordo" nos permitió mantener un control granular sobre el proceso sin necesidad de automatización completa, actuando Python como un puente entre la fuente de datos y nuestro sistema destino.

Razones por las que no utilizamos un Script Automatizado

Aunque los scripts automatizados son una opción válida y común en muchos contextos, tomamos la decisión consciente de no emplearlos por las siguientes razones:

Razones Técnicas

1. **Control y validación manual:** Al realizar un proceso semimanual con transbordo desde Python, pudimos inspeccionar visualmente los datos antes de su inserción definitiva, detectando posibles anomalías que un script automatizado podría pasar por alto.
2. **Complejidad del dataset:** El dataset seleccionado presentaba particularidades en su estructura que requerían decisiones puntuales durante la carga, las cuales eran más fáciles de manejar con intervención humana.

3. **Volumen manejable:** Con 11,562 registros, el volumen de datos era lo suficientemente moderado como para no requerir imperiosamente la automatización, permitiendo un proceso controlado sin sacrificar eficiencia.
4. **Garantía de integridad referencial:** La inserción controlada nos permitió verificar que cada registro respetara las relaciones establecidas entre tablas, evitando errores de llaves foráneas que podrían ocurrir en procesos masivos automatizados.

conclusión rápida: era más fácil y eficiente, observar nuestros datos con una fase manual que una automática directa o inyectable a la base de datos.

Razones Pedagógicas y de Aprendizaje

1. **Identificación de problemas estructurales:** Este enfoque permitió detectar y corregir sobre la marcha posibles deficiencias en el diseño de la base de datos, algo que un script automatizado habría ejecutado ciegamente.
2. **Alineación con el marco teórico:** Como se menciona en las páginas 6-10 del marco teórico sobre el impacto de las bases de datos en las organizaciones, comprender la naturaleza y calidad de los datos es fundamental para su aprovechamiento estratégico.

Razones Prácticas

1. **Documentación empírica:** El proceso manual generó un conocimiento “táctico” valioso sobre las características específicas de los datos y su comportamiento durante la inserción.

Resultado Final: 11,562 Datos Almacenados

Tras completar el proceso descrito, logramos poblar nuestra base de datos con **11,562 registros** de alta calidad. Y de hecho mientras hago este escrito el departamento de desarrollo sigue subiendo ese umbral a Día de hoy puedo informar de mas de 60k , demostrando que nuestra decisión fue correcta y el llenado de registros no se esta viendo comprometido por ningún problema externo.

Cómo las Investigaciones Previas Guiaron Nuestro Proceso

El marco teórico que desarrollamos previamente no fue un ejercicio académico aislado, sino que constituyó la brújula que orientó cada decisión en el proceso de llenado de nuestra base de datos.

Influencia del Concepto de Base de Datos (Página 2)

La definición fundamental de base de datos como "una herramienta que almacena información perteneciente a un mismo contexto, organizada y sistematizada lógicamente para su posterior recuperación, análisis o transmisión" nos recordó constantemente que nuestro objetivo no era simplemente almacenar datos, sino hacerlo de manera que facilitara su aprovechamiento futuro. Esto nos llevó a ser meticulosos en la organización y estructuración de los datos durante el proceso de transbordo desde Python.

Aportes de la Clasificación de Bases de Datos (Páginas 3-4)

El estudio de los diferentes tipos de bases de datos según su variabilidad, estructura y contenido fue determinante para:

- Hay que confirmar que nuestro diseño relacional era el adecuado para el tipo de información que manejaríamos
- Comprender que estábamos construyendo una base de datos dinámica (no estática), lo que implicaba considerar futuras operaciones de actualización y borrado
- Identificar que nuestro contenido correspondía a una base de datos especializada, orientada a un público con necesidades específicas como lo es una farmacia u hospital.

Impacto Organizacional de las Bases de Datos (Páginas 6-10)

Las secciones dedicadas al impacto en las organizaciones y la importancia de una buena base de datos nos sensibilizaron sobre la responsabilidad de nuestro trabajo. Conceptos como:

- ✓ "La recopilación de datos hace que se puedan tomar mejor las decisiones"
- ✓ "Las bases de datos no solo proporcionan grandes facilidades, rapidez y actualización, sino que además nos dan una cantidad de funciones con un alto nivel de ventajas"

Estos principios nos motivaron a asegurar que cada uno de los registros fuera insertado con la máxima calidad posible, entendiendo que de ellos podrían derivarse decisiones importantes.

Conexión con Problemas de Clasificación (Páginas 14-22)

Aunque nuestro objetivo inmediato era el llenado de la base de datos, la investigación sobre problemas de clasificación y su relación con las bases de datos nos hizo conscientes de que estábamos construyendo la materia prima para futuros análisis predictivos. Comprender que:

- ✓ "Las bases de datos constituyen la materia prima esencial sobre la cual se construyen y entrenan los modelos de clasificación"
- ✓ "La calidad, integridad y estructura de los datos almacenados" son críticas para el aprendizaje automático

Perspectiva del Data Warehouse (Páginas 24-25)

La sección sobre Data Warehouse nos proporcionó una visión a futuro de cómo nuestra base de datos podría integrarse en un ecosistema analítico mayor. Conceptos como:

- "Los sistemas de almacenamiento de datos pueden ingerir grandes cantidades de datos de una amplia gama de sistemas de origen"
- "La cobertura, la calidad y la estructuración intencional de los datos son requisitos no negociables para un análisis avanzado"

Estos principios reforzaron nuestra decisión de realizar un proceso de llenado controlado y cuidadoso.

Conclusión

El proceso de llenado de nuestra base de datos con 11,562 registros mediante el método directo con transbordo desde Python no fue una decisión arbitraria, sino el resultado de un análisis cuidadoso que consideró tanto el contexto tecnológico actual en México como las necesidades específicas de nuestro proyecto. La decisión de no utilizar scripts automatizados respondió a razones técnicas, pedagógicas y prácticas válidas que privilegiaron el control, la calidad y el aprendizaje sobre la mera eficiencia automatizada. El marco teórico desarrollado previamente se reveló no como un requisito académico a cumplir, sino como una guía práctica que iluminó cada etapa del proceso: desde el diseño de la estructura hasta la inserción final de los datos. La comprensión profunda de conceptos como tipos de bases de datos, tablas de hechos y dimensiones, y la relación con problemas de clasificación, nos permitió tomar decisiones informadas que garantizan no solo la funcionalidad presente de nuestra base de datos, sino también su potencial para integrarse en futuros desarrollos analíticos.

En última instancia, este proceso nos permitió trascender el simple almacenamiento de registros para generar una base de datos que, como señala nuestro marco teórico, constituye "la materia prima esencial" para la generación de conocimiento y la toma de decisiones fundamentadas.



BIBLIOGRAFIA:

La gran mayoría del texto aquí descrito este sujeto a su autor Isaac Yireel Andrade Nieto, tomando un punto de vista desde la experiencia en conjunto y comentarios de los desarrolladores, Espinosa Vazquez Cristopher, y Aguilar Gomez Lesly Dariana. también se utilizaron elementos externos como son investigaciones propias de este equipo de trabajo realizados por:

Kim Martínez Taesoo, Zertuche Zamora Sergio Gabriel y Sánchez Morales Jesus. y finalmente elementos externos de datos relevantes por la comunidad y datos encontrados o extraídos en internet como libros digitales, manuales o blogs profesionales.

Machine Learning y Python

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media. Guía práctica para implementar modelos de machine learning utilizando Python, relevante para nuestro uso de Python como lenguaje de transbordo.

McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media. Texto esencial para comprender el manejo de datos con Python, incluyendo la lectura de archivos CSV y la preparación de datos para inserción en bases de datos.

VanderPlas, J. (2016). *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly Media. Obra que cubre las herramientas fundamentales de Python para ciencia de datos, incluyendo manipulación de datos y visualización.

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley. Referencia esencial para comprender el modelado dimensional, las tablas de hechos y dimensiones que exploramos en nuestro marco teórico.

Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). Wiley.
Texto fundamental que establece los principios del data warehousing y su importancia en la inteligencia de negocios.

Artículos Científicos y complementarios.

Molina Marco, A. (2019). Bases de datos: Diseño y gestión. Garceta Grupo Editorial.
Obra en español que aborda el diseño y gestión de bases de datos en el contexto hispanohablante.

Hernández Orallo, J., Ramírez Quintana, M. J., & Ferri Ramírez, C. (2004).
Introducción a la minería de datos. Pearson Prentice Hall.
Texto en español que introduce los conceptos fundamentales de la minería de datos, incluyendo problemas de clasificación.

Armbrust, M., Ghodsi, A., Xin, R., & Zaharia, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. *Proceedings of CIDR '21*. https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf
Artículo que presenta el concepto de lakehouse como evolución de los data warehouses tradicionales.

Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. *ACM SIGMOD Record*, 26(1), 65-74. <https://doi.org/10.1145/248603.248616>
Revisión fundamental de las tecnologías de data warehousing y procesamiento analítico en línea.

Thusoo, A., et al. (2010). Hive - a petabyte scale data warehouse using Hadoop. *2010 IEEE 26th International Conference on Data Engineering (ICDE)*, 996-1005. <https://doi.org/10.1109/ICDE.2010.5447738>
Artículo que describe la implementación de data warehouses a gran escala utilizando tecnologías de big data.

Harrison, D., & Rubinfeld, D. L. (1978). Hedonic housing prices and the demand for clean air. *Journal of Environmental Economics and Management*, 5(1), 81-102. [https://doi.org/10.1016/0095-0696\(78\)90006-2](https://doi.org/10.1016/0095-0696(78)90006-2)

Estudio que presenta el dataset de viviendas utilizado como ejemplo de conexión entre regresión y clasificación en nuestro marco teórico.